

Raport Wydajności Systemu Primus 2026

1. Środowisko Testowe

Testy zostały przeprowadzone na lokalnym środowisku deweloperskim (Docker).

Specyfikacja Sprzętowa: * **CPU:** Intel Core i7-13700KF * **GPU:** NVIDIA GeForce RTX 3060 Ti (wykorzystywane przez Ollama/Local LLM) * **RAM:** 32 GB

Konfiguracja Programowa: * **Backend:** FastAPI + Uvicorn (4 workery) * **Baza Danych:** PostgreSQL 15 (AsyncPG, Isolation Level: Read Committed) * **AI Engine:** Ollama (Model: qwen3:4b) * **Narzędzie Testowe:** Locust (Headless Mode)

2. Scenariusze Testowe (“Extreme”)

A. Scenariusz Standardowy (200 Użytkowników)

Symulacja intensywnej pracy magazynu: 200 jednoczesnych pracowników wykonujących operacje wyszukiwania, alokacji i generowania raportów.

Komenda: poetry run locust -f scripts/locustfile.py StandardUser -u 200 -r 10 --run-time 1m

Wyniki: | Metryka | Wartość | Komentarz | | :— | :— | :— | | **Liczba Ządań (Total)** | **8,197** | W ciągu 60 sekund | | **Przepustowość (RPS)** | **~136 req/s** | Stabilne obciążenie | | **Opóźnienie (Odczyt)** | **9 ms** (mediana) | Wyszukiwanie produktów, listowanie stanów | | **Opóźnienie (Zapis)** | **~500 ms** (mediana) | Transakcyjne operacje magazynowe | | **Opóźnienie (Raport)** | **120 ms** (mediana) | Generowanie PDF (Celery async) | | **Błędy** | **0%** | System w pełni stabilny |

B. Scenariusz AI (20 Użytkowników)

Symulacja 20 pracowników jednocześnie wydających komendy głosowe. Jest to test skrajny dla pojedynczej karty graficznej.

Komenda: poetry run locust -f scripts/locustfile.py AIUser -u 20 -r 2 --run-time 1m

Wyniki: | Metryka | Wartość | Komentarz | | :— | :— | :— | | **Liczba Ządań (Total)** | **276** | Limitowane przez prędkość inferencji GPU | | **Przepustowość (RPS)** | **~4.2 req/s** | Kolejowanie zadań w Ollama | | **Opóźnienie (Mediana)** | **3,500 ms** | Czas oczekiwania w kolejce + inferencja | | **Opóźnienie (Max)** | **5,800 ms** | I tak poniżej timeoutu (120s) | | **Błędy** | **0%** | Brak odrzuconych połączeń (Connection Refused/Timeout) |

3. Wnioski

- Backend (FastAPI/Postgres):** Jest ekstremalnie wydajny na procesorze i7-13700KF. Obsługa 200 jednoczesnych użytkowników (co odpowiada magazynowi zatrudniającemu ok. 1000 osób na zmianę) skutkuje czasami odpowiedzi rzędu milisekund.
- AI (Ollama/GPU):** Karta RTX 3060 Ti radzi sobie z kolejkowaniem 20 równoległych zapytań. Opóźnienie rośnie liniowo, ale system pozostaje stabilny. Dla produkcji zalecane jest skalowanie horyzontalne (więcej instancji Ollama) lub użycie komercyjnego API (OpenAI) przy tak dużym obciążeniu.

3. **Wniosek:** Są to w pełni wystarczające wyniki dla większości zastosowań, a otrzymane zostały na tanim sprzęcie konsumenckim.